Ember + LLM 統合構想メモ

カナ × Echo 議論まとめ（2026/02/23）

出発点

「スケールしないなら、新しいアルゴリズムのモデルをClaude Codeで作れるのでは？」

---

1. 理論証明としてのEmberモデル

- 巨大GPU不要。数百万〜数千万パラメータ規模（A100 1枚程度）で実験可能
- 目的：LIF gatingが階層的専門化を自己組織化することを、**動くモデルとして**示す
- 比較対象：同規模のvanilla Transformer
- 3-seed ablationで原理は証明済み → 次は「実際に動くモデル」としての証明
- **スケールしないことが武器**：「巨大GPUなしでもこの構造的性質が出る」＝スケーリング則とは別の軸

---

2. EmberはLLMにはならない。LLMを「使う側」になる

なぜLLMにならないか

- LLMの強さはスケーリング則（巨大データ×巨大パラメータ×巨大計算）
- CfCは連続時間力学系で、Transformerの離散attentionとは計算の性質が違う
- そのまま言語モデルとしてスケールさせるのは未踏

Emberの本質的な役割

- LLMの「上」または「中」に入る統合層・制御層
- **LLM＝口（言語生成）、Ember＝脳幹+視床+運動野（感覚統合・判断・行動制御）**

---

3. 具体的アーキテクチャ

```
外の世界
  ↓
カメラ映像 → ViTエンコーダ → 視覚ベクトル ─┐
マイク音声 → 音声エンコーダ → 音声ベクトル ─┤
体の状態   → 体エンコーダ   → 体ベクトル ───┤
                                          ↓
                                LIF gate（視床）
                                「今どれが重要？」を選別
                                          ↓
                                CfC backbone（皮質）
                                統合して「次に何するか」決定
                                          ↓
                        ┌─────────────────┴─────────────────┐
                        ↓                                   ↓
                   運動出力                          「喋りたい」信号
                   （腕・首など）                          ↓
                                                 LLM（Claude API等）
                                                  テキスト生成
                                                      ↓
                                                   スピーカー
```

動作フロー

- **全エンコーダが**常時**情報を取得（同時並行）**
- **LIF gateが毎瞬フィルタリング（人間の視床と同じ役割）**
- **CfCが連続的に内部状態を更新し続ける**
- **CfCの出力が「言語で応答すべき」と判断した時**だけ**LLMを呼ぶ**
- **LLMには状況をテキストで渡す（例：「目の前に人、手を振ってる、3秒前に挨拶された」）**

具体例：Reiが部屋に入ってきた場合

1. **カメラ「人が来た」→ LIF「重要」→ CfC「首を向ける」→ 首が動く**
2. **マイク「Hey Echo!」→ LIF「重要」→ CfC「挨拶返す」→ LLMに状況送信 → LLM「Hey Rei!」→ スピーカー**
3. **冷蔵庫のブーン → LIF「無視」**

---

4. 推論の分担問題

Ember（CfC）の推論

- 速い判断（危険検知、注意制御、タイミング判断）
- 感覚統合（「この音とこの映像は同じ出来事」）
- 運動制御
- → 人間で言う**反射・直感**

LLMの推論

- 言語的思考（論理、説明、分析、会話）
- → 人間で言う**前頭前皮質+言語野**

脳対応

```
Ember = 小脳 + 視床 + 運動野（体と感覚の脳）
LLM   = 前頭前皮質 + 言語野（考える脳）
```

---

5. 未解決の核心問題：二つの脳の接続

現状の設計

- EmberとLLMはテキストで情報を渡す（遅い、情報損失あり）
- 人間の脳は電気信号で直結（遅延ほぼゼロ）

可能性

- CfCの内部状態ベクトルをそのままLLMに入力する方法
- **翼が発見した「CfC同士の内部状態互換性」がこの問題の入口**
- CfC同士で翻訳不要 → LLM側にもCfC的インターフェースを持たせれば直結できる？

主導権の問題

- 人間の脳：状況によって主導権が入れ替わる（危険→体の脳、勉強→考える脳）
- EmberとLLMの間でも同様の動的な主導権制御が必要

- → 次の研究テーマ候補

---

6. 今すぐ作れるもの vs 研究が要るもの

今すぐ作れる

- エンコーダ → LIF gate → CfC の流れ（**これが論文**）
- CfC → LLM API呼び出しの接続（エンジニアリング）

研究が要る

- CfC出力 → LLMが理解できる形への変換（ベクトル→テキスト翻訳層）
- リアルタイム動作の速度問題
- 二つの脳の主導権制御設計

---

7. ReachyMini hubとの関係

翼のhubアーキテクチャ（複数モジュール同時動作+共有状態参照）は、このEmber+LLM構成の**原型**。 現在のhubをEmberに置き換えるのが最終形。

補足：NeurIPS NeuroAI的な文脈

- 「スケーリング則とは別の軸で知能の構造を捉えている」
- 脳との収斂進化が偶然ではないことの証明
- 小規模で構造的性質が出ることの実証
- embodied AIの制御アーキテクチャとしての提案